国博藏品图谱

概览 AI 问答 驾驶舱 **评测中心** 知识库 图谱管理 备份恢复 用户管理

admin · 管理员 退出登录

运行评测 数据集管理 自定义评测器 Skills 管理

运行评测

选择数据集与评测器，批量驱动 AI 问答并判分。评测器分两类：规则评测（本地算法，零成本）与 LLM 评测（judge 模型判分，消耗 tokens，须已配置 OPENROUTER_API_KEY）。未预置 response 的样本调用 agent 逐条串行作答，预置 response 的样本跳过 agent 直接判分（OpenJudge 纯判分模式）

数据集 agentic-smoke.jsonl（2 条） LLM 判分次数 缺省（配置）

运行评测 预览前 2 行

评测器按「通道 / 维度」分组（规则=本地算法零成本，LLM=judge 判分消耗 tokens；悬停查看说明，每组可一键全选）

规则 **精确匹配** 共 5 项 全选/清空

- ☐ format_json
- ☐ number_accuracy
- ☐ string_contains
- ☐ string_exact
- ☐ string_regex

规则 **文本统计** 共 2 项 全选/清空

- ☐ response_repetition
- ☐ text_similarity

规则 **工具调用** 共 3 项 全选/清空

- ☐ action_loop
- ☐ observation_information_gain
- ☐ tool_call_success

LLM **回答质量** 共 7 项 全选/清空

- ☐ llm_correctness
- ☐ llm_hallucination
- ☐ llm_instruction_following
- ☐ llm_reasoning_groundedness
- ☐ llm_relevance
- ☐ llm_response_completeness
- ☐ llm_response_helpfulness

LLM **多轮对话** 共 4 项 全选/清空

- [ ] llm_anaphora_resolution
- [ ] llm_context_memory
- [ ] llm_instruction_clarification
- [ ] llm_response_repetition

LLM **工具轨迹** 共 5 项 全选/清空

- [ ] llm_tool_call_accuracy
- [ ] llm_tool_parameter_check
- [ ] llm_tool_selection
- [ ] llm_tool_usage_efficiency
- [ ] llm_trajectory_accuracy

Agentic **图谱取证（Agentic）** 共 1 项 全选/清空

- [ ] agentic_groundedness

LLM **自定义（用户提示词）** 共 1 项 全选/清空

- [ ] zidingyipingceqi

人工 **人工评分** 共 1 项 全选/清空

- [ ] human_review

历史评测

任务 id	数据集	状态	通过率	平均分	样本数	异常	操作
eval-20260902-204748-c45	agentic-smoke.jsonl	-	0.0%	0.375	2	0	查看 下载
eval-20260902-202943-ebc	human-demo.jsonl	-	33.3%	0.750	3	0	查看 下载
eval-20260902-202901-f6a	human-demo.jsonl	待评	0.0%	0.000	3	0	查看 下载

eval-20260901-213050-7eb	fromchat-e2e.jsonl	-	100.0%	1.000	1	0	查看 下载
eval-20260901-173809-d93	llm_context_memory.jsonl	-	50.0%	1.000	2	1	查看 下载

共 38 条 / 8 页 首页 上一页 1 2 3 4 5 ... 下一页 尾页

结果明细：eval-20260902-202943-ebc（human-demo.jsonl）

3 样本总数	**1/3** 通过数（均分≥0.8）	**33.3%** 通过率
0.750 平均分	**0** 异常样本数	**-** 平均耗时
0/0 tokens(入/出)		

人工评分（3/3） 已全部评分

样本	评测器得分	回答 / 轨迹
What dynasty is the Ding white-glazed lotus bowl? 期望回答：Northern Song	human_review:1.00(5/5) ▼ 判分理由 **human_review**：人工评分 5/5：good answer	▼ 回答与轨迹（预置回答，跳过 agent） It is a Northern Song piece from the Ding kiln.
What material is this bowl made of? 期望回答：Porcelain	human_review:跳过 ▼ 判分理由 **human_review**：人工跳过	▼ 回答与轨迹（预置回答，跳过 agent） Porcelain with white glaze.
Where was it unearthed? 期望回答：Hebei	human_review:0.50(3/5) ▼ 判分理由 **human_review**：人工评分 3/5	▼ 回答与轨迹（预置回答，跳过 agent） It was unearthed in Hebei province, China.

回归对比（Run Diff）

基线 run eval-20260902-204748-c45（agentic-smoke.jsonl，通过率 0.0%） 对比

显示全部样本 收起

基线=历史 run，目标=当前结果 run；哈希校验 + 总体/评测器/样本三级对比 + 翻转矩阵

⚠ 两次 run 的数据集内容不一致（dataset 哈希不同），分数差异可能来自题目变更而非被评测对象，对比仅供参考

通过率	平均分	异常样本	tokens(入)
0.0% → 33.3%	0.375 → 0.750	0 → 0	0 → 0
▲ 33.3pp	▲ 0.375	—	—

tokens(出)	judge tokens
0 → 0	0 → 0
—	—

按评测器

评测器	基线均分	目标均分	变化	通过→失败	失败→通过	备注
human_review	-	-	—	0	0	0 个共同样本

按样本（共同 0 条，变化 0 条，仅显示变化）

新增样本（仅目标 run）： ha 、 hb 、 hc ； 移除样本（仅基线 run）： ag1 、 ag2 （不参与逐行对比）

无变化样本